

시퀀셜 모델 생성 : `model = keras.Sequential()`

레이어 추가 : `model.add(~Dense(units=n(or 숫자만 입력 ), activation='tanh'))`  
(중간에 `input_shape=(-2,)` 넣어도 됨)

로스 옵티마이저 메트릭 입력(컴파일) : `model.compile()` 손실 함수, 옵티마이저, 평가 지표 설정한다.

학습 : `model.fit(X, y, batch_size, epochs=100)`

결과값 확인 : `model.predict(구할 데이터)`

파라미터 개수 구하기

입력 개수가 2이고 히든 2개 유닛 출력 1개 유닛 인 경우

1.  $2*2+2$ (유닛당 바이어스값 1개씩) 6개 (3개면  $2*3+3$ ), 2.  $2*1+1$  총 3개

`evaluate(x=None, y=None)`: 테스트 모드에서 모델의 손실 함수 값과 측정 항목 값을 반환

`add(layer)`: 레이어를 모델에 추가한다.

`model = Sequential()`

`model.add(Dense(units=2, input_shape=(2,), activation='sigmoid'))` -> 히든레이어

`model.add(Dense(units=1, activation='sigmoid'))` -> 출력층

단 `def conv2d_block(x, channel):`

`x = Conv2D(channel, 3, padding="same")(x)`

`x = BatchNormalization()(x)`

`x = Activation("relu")(x)`

`x = Conv2D(channel, 3, padding="same")(x)`

`x = BatchNormalization()(x)`

`x = Activation("relu")(x)`

`return x` 이렇게 쓰기도 함

`conv2d_block` 함수는 보통 함수형 API 방식에서 사용한다.  
Sequential 모델에서는 이런 식으로 레이어 쌓기 어려움  
`tf.keras.models.Model`로 함수형으로 정의할 때 많이 씀

`model.add(tf.keras.layers.Dense(units=2, input_shape=(2,), activation='sigmoid'))`

`= model.add(tf.keras.layers.Input(shape=(2,)))`

`model.add(tf.keras.layers.Dense(2, activation='sigmoid'))`

모델: 하나의 신경망을 나타낸다

입력 데이터: 텐서플로우 텐서 형식

옵티마이저: 학습을 수행하는 최적화 알고리즘이다. 학습률과 모멘텀을 동적으로 변경

`Input(shape, batch_size, name)`: 입력을 받아서 케라스 텐서를 생성하는 객체

`Dense(units, activation=None, use_bias=True, input_shape)`: 유닛들이 전부 연결된 레이어

모델 저장 : `model.save('./~')`      모델 로드 : (로드모델 импорт 필요) `model = load_model('./~')`

손실함수(`loss = ''`)

회귀 손실함수 : `mse(MeanSquaredError)`

분류 손실함수 : `binary_crossentropy` - 강아지인지 강아지가 아닌지만

`categorical_crossentropy` - 정답 원하던 경우 강아지 고양이 호랑이 분류

`sparse_categorical_crossentropy` - 정답 정수인 경우 강아지 고양이 호랑이 분류

경사하강법(`optimizer = ''`)

GD(경사하강법 - 전체 데이터), SGD(확률적 경사하강법 - 랜덤 일부 데이터 추출)

NAG, Adagrad, RMSprop, Adam(가장 많이 사용)

정확도(`Metric = []`)

예측값이 정답 레이블과 얼마나 같은지 횟수 계산

(mse같은 손실함수를 써도 되나 주로 `accuracy` 사용)

batch\_size -> 1epoch동안 전체샘플수/ batch\_size의 크기로 가중치 업데이트(램, 속도, 안정성 고려)  
배치 사이즈의 크기마다 한번씩 가중치를 업데이트함 (너무 커지면 느려지고 작으면 불안정)

하이퍼 매개변수란? 학습률 은닉층을 몇 개로 할 것이며, 은닉층의 개수나 유닛, 배치의 크기를 말함  
정수형 -> 원핫인코딩 하는 법 : 변수 = tf.keras.utils.to\_categorical(바꿀 변수)

문자열 -> 원핫인코딩 하는 법 :

원핫 = boolType 인코딩

```
import numpy as np
X = np.array(['Korea', 'Japan', 'China'])

from sklearn.preprocessing import OneHotEncoder
onehotencoder = OneHotEncoder()
XX = onehotencoder.fit_transform(X.reshape(-1,1)).toarray()
print(XX)
```

```
import numpy as np #booltype
import pandas as pd #판다스 사용
X = np.array(['Korea', 'Japan', 'China'])
XX_df = pd.get_dummies(X)
XX = XX_df.values
print(XX)
```

문자열 -> 정수형 데이터 처리 하는 법 :

```
for ix in train.index: \n if train.loc[ix, 'Sex']=="male": \n train.loc[ix, 'Sex']=1 \n else: \n train.loc[ix, 'Sex']=0
```

쉬운방식 import pandas as pd \n train['Sex'] = train['Sex'].replace({"male": 1, "female": 0})

원핫 인코딩에서 결과값 총 합을 1로 바꾸는 법 : output의 activation을 softmax  
(따라서 회귀 이용하는 경우 output의 결과에 활성화함수(엑티베이션)를 입력하지 않음)

엑셀에서 데이터 읽어오기

```
train = pd.read_csv("train.csv", sep=',')
```

->sep는 분할 방법 ' '등을 분할, (pd....).strip 써서 공백제거, ().lower로 소문자화도 가능

필요없는 컬럼 삭제

```
train.drop([컬럼명, 컬럼명], inplace = True, axis=1)
```

결손치 존재 데이터 행 삭제

```
train.dropna(inplace=True)
```

과적합(overfitting) : 학습이 훈련 데이터에 특화되어 데이터의 전체적인 패턴을 학습하지 못하는 것

과소적합(underfitting) : 너무 단순하게 학습되어 패턴을 제대로 파악하지 못하는 것

과적합 해결법 :

1. 검증 데이터 이용(6:2:2)하여 검증 손실이 감소하지 않을 때 EarlyStopping이용

(callback = EarlyStopping(monitor='val\_loss', patience=20)) #중단 시점

path = "./~" #저장 경로 지정

checkpoint = ModelCheckpoint(filepath = path, monitor='val\_loss', verbose=1, save\_best\_only = True #최적화 모델 저장 설정

hist=model.fit(X, y, epochs=n, batch\_size=n, validation\_split=0.25, verbose=1, callbacks=[callback, checkpoint]))

2. 레이어 사이에 Dropout 추가

model.add(tf.keras.layers.Dropout(0.5)) (Dense쓰면 Dense(16, activation=' ', -))

## 정규화 방법

```
from sklearn.preprocessing import MinMaxScaler
mms=MinMaxScaler()
mms.fit(x)
print(x.head())
x = mms.transform(x)
x = pd.DataFrame(x, columns=x.columns, index = list(x.index.values))
```

컬러이미지shape (height, width, rgb ==3)      흑백이미지shape (height, width)

## 컨볼루션 연산 하는 법

입력 [[2,1,0] [1,3,2] [4,3,2]] 인 경우  $2*1+ 1*2+ 0*0+ 1*1+ 3*2+ 2*0+ 4*3+ 3*2+ 2*4$

커널 [[1,2,0] [1,2,0] [3,2,4]] = 37

[[ -1.0,1] [-2.0,2] [-1.0,1]] 커널을 사용하는 경우 상하선 표시가 잘됨

완전 연결 신경망(영상(이미지)에서는 사용 불가) : Fully Connected layer, Densely connected layer

CNN : Convolutional Neural Network (영상사용 가능 (필요한 부분만 사용))

보폭(stride) : 커널을 적용하는 거리 (1이면 한칸마다 2면 두칸마다)

tf.keras.layers.Conv2D

(filters, kernel\_size, strides=(1,1), activation=None, input\_shape=(11,), padding='valid')(입력data)

filters : 필터 개수 (그냥 숫자로 표기)

kernel\_size : 필터 크기 (3이면 3\*3)

strides : 보폭

activation : 활성화 함수

input\_shape : 입력 배열의 형상(기준 개수) (=1:] 이렇게도 사용 가능)

padding : 패딩 (디폴트는 valid, 선택하여 same)

28, 28, 1에서

1은 채널 수이다.

1이면 1개의 채널로 흑백을 표현하고

컬러 이미지는 채널 3개를 가진다.

(채널 3개는 R, G, B)를 말한다.

valid시 필터에 따른 출력 사이즈 = 입력 사이즈 - (커널 사이즈 - 1)

```
model = keras.Sequential(
    [
        keras.Input(shape=input_shape),
        layers.Conv2D(32, kernel_size=(3, 3), activation="relu"),
        layers.MaxPooling2D(pool_size=(2, 2)),
        layers.Conv2D(64, kernel_size=(3, 3), activation="relu"),
        layers.MaxPooling2D(pool_size=(2, 2)),
        layers.Flatten(),
        layers.Dropout(0.5),
        layers.Dense(num_classes, activation="softmax"),
    ]
)
```

input\_shape = (28, 28, 1)

3\*3 -> 26, 26, 1

pool -> 13, 13, 1

3\*3 -> 11, 11, 1

pool -> 5, 5, 1

flatten -> 25

Tip : Flatten은 Dense 쓰기 전에 사용

Param을 구하는 공식은

(커널 너비, 높이, 채널 수 곱하고 +1 ) 필터수를 곱한

너비와 높이는 해당 커널 사이즈를 사용

하지만 입력 채널 수 라는 것을 곱할 수는


이전 레이어의 채널 수를 곱한다.

즉 13, 13, 32가 이전 출력이라면

해당 레이어 커널 사이즈가 3, 3인 곳의 파람을 계산할

$3 * 3 * 32 + 1$ 한 결과를 해당 레이어 필터 수량 곱한

이것이 파람 결과를 구하는 공식이다.



Model: "sequential"		
Layer (type)	Output Shape	Param #
=====Model: "sequential"=====		
Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 26, 26, 32)	320
max_pooling2d (MaxPooling2D)	(None, 13, 13, 32)	0
conv2d_1 (Conv2D)	(None, 11, 11, 64)	18496
max_pooling2d_1 (MaxPooling2D)	(None, 5, 5, 64)	0
flatten (Flatten)	(None, 1600)	0
dropout (Dropout)	(None, 1600)	0
dense (Dense)	(None, 10)	16010
=====		
Total params: 34,826		
Trainable params: 34,826		
Non-trainable params: 0		

데이터 증대\* (data augmentation) : 방법은 (10)px 이동, 노이즈 추가, 각도 돌리기, 반전, 확대/축소  
전이 학습\*(transfer learning) : 이미 학습한 신경망의 모델과 가중치를 조정해 새 문제에 적용하는 것  
(Xception, VGG, Resnet, Mobilenet 등)  
lib로 존재하는걸 임포트해서 씀

super resolution -> 업스케일링으로 사용  
style transfer -> 이미지 화풍 변경 가능

시계열 데이터 : 시간이나 공간등의 순서가 있는 데이터 (주식, 텍스트, 오디오)

RNN\*(Recurrent Neural Network) : 시계열 데이터 처리를 위해 이전 내용이 학습되는 CNN  
(지나면서 계속 입력을 하고 결과값 데이터로 학습이 해야함 - 과거를 기억)

LSTM\*(Long-Shor Term Memory) : RNN에서 데이터 저장여부를 선택 가능함

형식은 `model.add(SimpleRNN(16, activation='tanh', return_sequences=True, input_shape=()))`  
(단 RNN1은 return\_sequences가 빠짐)

자연어 처리 순서 : 음성인식 -> 자연어 이해 -> 대화 -> 응용 프로그램 조직 -> 로직 -> 처리기 ->  
자연어 생성 -> TTS (요약 : 음성 -> 음성인식 -> 텍스트 -> 자연어 처리)

다음 처리 순서: 텍스트 -> data정제 -> 텍스트 전처리(word embedding) -> 딥러닝 -> 분류 -> 처리

텍스트 전처리 : 1.토큰화 2.특수문자 제거 3.소문자 변환 4.불용어 제거

토큰화 : 주로 단어 단위로 나눔

실제로 자연어 처리는 이렇게 이루어진다고 한다.

특수문자 제거 : 구두점이나 특수문자를 제거

요약 버전인 듯 하다.

소문자 변환 : .lower()등을 이용해 전부 소문자로 변환

음성인식 → 텍스트처리 → 토큰화전처리 → 임베딩 → 모델 → 결과

불용어 제거 : 내용 분석에 도움되지 않는 단어들 제거

자연어 처리시 정수처리(숫자가 너무 커짐), 원핫(너무 길어짐)의 문제로 워드 임베딩을 사용  
(예로 blue = [-0.7, 1.4, -0.2, -0.1] 의 밀집 벡터로 표현 )

샘플의 패딩 : 하나만 있으면 앞에 0으로 채움

LLM\*(Large Language Model) : 방대한 데이터로 사전 학습된 초대형 딥 러닝 모델

Chat GPT\* : Transformer 모델 기반으로 Generative Pre-trained Transformer

Transformer 모델은 self-attention기반임

강화학습\* : 딥러닝을 탑재한 에이전트가, 주어진 환경에서 스스로 행동해서 (시행착오로)학습

- 에이전트(Agent) : 강화 학습을 하는 객체
- 환경(Environment) : 에이전트가 작동하는 물리적 세계
- 상태(State) : 에이전트의 현재 상황 (예시로 미로에서 에이전트의 위치)
- 보상(Reward) : 환경으로부터의 피드백 (성공 실패에 대한 보상)
- 액션(Action) : 에이전트의 행동